

MEMOIRE DE FIN D'ETUDES
POUR OBTENIR LE DIPLOME D'INGENIEUR D'ETAT

FILIERE : INGENIERIE FINANCIERE ET AUDIT (IFA)

OPTION : Ingénierie Financière (IF)

**Optimisation dynamique de portefeuille des entreprises cotées en
Bourse de Casablanca basée sur la prévision de risque à travers la
création et l'utilisation d'un agent IA**

Réalisé par : M. Akram Marouane

Soutenu publiquement le :

Encadrant pédagogique : Pr. Mohammed FIKRI

Encadrant professionnel : Mme. Ouidad Ouardi, Alphavest Asset Management

Membres de jury :

- Pr. Mohammed FIKRI
- Pr.
- Pr.

Lieu de stage : Alphavest Asset Management, Casablanca

Date du début de stage : 25 / 02 / 2026

Date de la fin de stage : 25 / 06 / 2026

Année universitaire : 2025-2026

Dédicaces

À mes chers parents,

pour leur amour inconditionnel, leurs sacrifices et leur soutien indéfectible tout au long de mon parcours.

À mes frères et sœurs,

pour leur encouragement constant et leur présence bienveillante.

À mes amis et collègues,

pour les échanges enrichissants et la solidarité partagée durant ces années d'études.

« Le succès n'est pas final, l'échec n'est pas fatal : c'est le courage de continuer qui compte. »

— Winston Churchill

Remerciements

Au terme de ce travail, il m'est agréable de m'acquitter d'un agréable devoir en exprimant mes sincères remerciements à toutes les personnes qui ont contribué, de près ou de loin, à l'élaboration de ce mémoire de fin d'études.

Je tiens tout d'abord à exprimer ma profonde gratitude à mon encadrant pédagogique, Monsieur le Professeur Mohammed FIKRI, pour la qualité de son encadrement, sa disponibilité, ses précieux conseils et la rigueur scientifique qu'il m'a transmise tout au long de ce travail. Ses orientations ont été déterminantes dans la conduite de cette recherche.

Je remercie chaleureusement Madame Ouidad Ouardi, mon encadrante professionnelle au sein d'Alphavest Asset Management, pour son accueil chaleureux, sa confiance et l'accompagnement bienveillant qu'elle m'a apporté durant toute la période de stage. Sa connaissance approfondie du marché financier marocain et sa disponibilité ont été d'une aide précieuse pour la réussite de ce projet.

Mes remerciements s'adressent également à l'ensemble de l'équipe d'Alphavest Asset Management pour leur accueil, leur esprit d'équipe et le cadre professionnel stimulant qu'ils ont mis à ma disposition. Cette expérience au sein d'une société de gestion d'actifs spécialisée dans les OPCVM marocains a considérablement enrichi ma compréhension des marchés financiers et de la gestion de portefeuille.

Je tiens également à remercier l'École Marocaine des Sciences de l'Ingénieur (EMSI) et l'ensemble du corps professoral de la filière Ingénierie Financière et Audit pour la qualité de la formation dispensée, qui m'a fourni les fondements théoriques et méthodologiques nécessaires à la réalisation de ce travail.

Enfin, je dédie ces remerciements à ma famille pour son soutien moral et affectif tout au long de mes études, ainsi qu'à mes amis et collègues pour leur solidarité et les échanges fructueux qui ont jalonné ce parcours.

PARTIE I

CADRE THÉORIQUE ET CONCEPTUEL

Introduction

Avant de plonger dans l'implémentation technique d'un agent IA capable d'optimiser dynamiquement un portefeuille d'actions cotées à la Bourse de Casablanca, il est indispensable de poser les fondations théoriques sur lesquelles repose ce travail. Car si l'intelligence artificielle offre des capacités de traitement et d'apprentissage inédites, elle ne saurait se substituer à la compréhension des mécanismes financiers fondamentaux ; elle les prolonge et les amplifie en leur donnant une dimension computationnelle et adaptative que les méthodes classiques ne permettaient pas d'atteindre.

Cette première partie s'articule autour de deux chapitres complémentaires. Le premier revisite les théories classiques de la gestion de portefeuille : pourquoi et comment Markowitz a révolutionné notre façon de penser le risque, comment la frontière efficiente guide encore aujourd'hui les décisions d'allocation, et quels sont les vingt indicateurs de risque que nous mobiliserons dans notre analyse empirique des entreprises cotées à la BVC. Le second chapitre sera consacré à l'intelligence artificielle appliquée à la finance : définition des agents IA, architectures disponibles, et état de l'art des applications en gestion d'actifs.

L'objectif n'est pas de dresser un inventaire exhaustif de la littérature financière, mais de construire, étape par étape, le cadre conceptuel qui justifie nos choix méthodologiques et donne du sens aux résultats que nous présenterons en Partie II. Chaque concept théorique présenté ici trouve un écho direct dans notre implémentation pratique : la frontière efficiente de Markowitz dans notre module d'optimisation, les mesures de risque de queue dans notre tableau de bord d'évaluation, et les architectures d'agents IA dans la conception de notre système autonome de gestion.

Chapitre 1

Fondements de la gestion de portefeuille et mesure du risque

La gestion de portefeuille est, en essence, une réponse à une tension permanente entre deux objectifs contradictoires : maximiser le rendement et minimiser le risque. Cette tension, que tout investisseur ressent intuitivement, n'a reçu une formalisation mathématique rigoureuse qu'au milieu du XXe siècle. Depuis lors, les modèles se sont multipliés, affinés et parfois contredits. Ce chapitre en retrace les lignes essentielles, en gardant constamment à l'esprit leur application au marché boursier marocain.

Section 1 : La théorie moderne du portefeuille

1.1 L'investisseur rationnel face au risque : fondements comportementaux

Avant de parler d'optimisation, encore faut-il se demander ce que cherche réellement un investisseur. La réponse classique de la théorie économique est celle de l'utilité espérée : face à l'incertitude, un agent rationnel maximise l'espérance de sa fonction d'utilité. Or si cette fonction d'utilité est concave, ce qui traduit l'aversion au risque, et l'agent préférera systématiquement un gain certain à une loterie d'espérance équivalente. Autrement dit, il accepte de sacrifier une partie du rendement espéré en échange d'une réduction de l'incertitude (Poncet & Portait, 2009).

C'est sur cette base comportementale que Markowitz (1952) a construit son modèle. Il fait le pari que, sous certaines conditions (soit une fonction d'utilité quadratique, soit une distribution gaussienne des rendements), les préférences d'un investisseur averse au risque peuvent être entièrement représentées par deux paramètres seulement : l'espérance de rendement $E(R_p)$ et la variance $\sigma^2(R_p)$. Ce critère dit « E-V » constitue le fondement de toute l'architecture théorique qui s'ensuit. Son avantage décisif réside dans sa simplicité opérationnelle : il permet de raisonner dans un espace bidimensionnel, d'y représenter graphiquement tous les portefeuilles possibles, et d'identifier visuellement les plus efficaces (Poncet & Portait, 2009).

Il faut cependant noter dès à présent une limite fondamentale de ce cadre : les hypothèses de normalité des rendements et d'utilité quadratique sont rarement vérifiées en pratique. El Bouhadi et al. (2008) ont montré que sur la BVC, les distributions de rendements sont significativement asymétriques et leptokurtiques, comme en témoignent les tests de Jarque-Bera appliqués aux 31 valeurs de leur échantillon. Cette réalité empirique justifie que nous ne nous limitons pas à la variance comme seule mesure de risque, et que nous

mobilisations un ensemble bien plus large d'indicateurs, ce qui fait précisément l'objet de la Section 1.2.

1.2 L'approche moyenne-variance et l'effet de diversification

Pour un portefeuille composé de n actifs affectés de poids $w_1, w_2, \dots, w_n$, le rendement espéré et la variance s'écrivent :

$$E(R_p) = \sum_i w_i \cdot E(R_i)$$
$$\sigma^2(R_p) = \sum_i \sum_j w_i \cdot w_j \cdot \sigma_{ij} = w^T \Sigma w$$

La seconde formule est la clé de voûte du modèle. Elle révèle que la variance du portefeuille dépend non seulement des variances individuelles des actifs (termes $i = j$), mais surtout des covariances entre eux (termes $i \neq j$). Lorsque deux actifs évoluent en sens contraire (corrélation négative ou faible), leur association réduit la variance totale du portefeuille en deçà de la moyenne pondérée de leurs variances individuelles. C'est l'effet de diversification, résumé par la formule souvent citée : « ne pas mettre tous ses œufs dans le même panier » (Rhatous & Daoui, 2020).

Cobbaut et al. (2015), cités par Rhatous et Daoui (2020), formalisent cette idée ainsi : « Diversifier, c'est réduire le risque de son investissement en le répartissant entre plusieurs titres. » Mais la diversification a ses limites : elle ne peut éliminer que le risque spécifique propre à chaque titre. Il subsiste toujours une composante non diversifiable, à savoir le risque systématique, qui correspond aux fluctuations communes à l'ensemble du marché et qui ne peut être réduite par aucune combinaison de titres.

Dans le contexte marocain, l'effet de diversification se heurte à une contrainte structurelle importante : la concentration sectorielle de la BVC. Les grandes capitalisations y sont dominées par les banques, les télécoms et l'immobilier, secteurs dont les rendements tendent à être positivement corrélés, notamment en période de stress de marché. Cette concentration réduit mécaniquement les bénéfices de la diversification intra-marché et plaide pour une approche dynamique capable d'identifier, à chaque période, les poches de décorrélation exploitables, ce que notre agent IA s'efforcera de faire.

1.3 La frontière efficiente : construction et interprétation

L'ensemble des portefeuilles qui minimisent la variance pour chaque niveau de rendement espéré forme la frontière efficiente. Seuls les portefeuilles situés sur cette frontière méritent l'attention d'un investisseur rationnel : en dessous, un portefeuille offrant le même rendement pour un risque moindre existe ; au-dessus, aucun portefeuille accessible ne délivre ce niveau de rendement (Markowitz, 1952 ; Poncet & Portait, 2009).

Mathématiquement, chaque portefeuille efficient est solution du programme quadratique :

$$\min \sigma^2(R_p) = w^T \Sigma w$$

$$s.c. \ w^T \mu = \mu_0, \ w^T 1 = 1, \ w_i \geq 0 \ \forall i$$

La dernière contrainte ($w_i \geq 0$) interdit les ventes à découvert, ce qui est particulièrement pertinent dans le cadre réglementaire marocain où celles-ci restent limitées. En faisant varier μ_0 sur l'ensemble des rendements espérés atteignables, on trace la frontière efficiente dans le plan $(\sigma, E(R))$, représentée graphiquement sous forme d'une hyperbole dont seule la branche supérieure est pertinente pour un investisseur rationnel.




Figure 1.1 : La frontière efficiente de Markowitz dans l'espace rendement-risque

Source : Adapté de Markowitz (1952) et Poncet & Portait (2009)

La position d'un investisseur sur cette frontière dépend de son degré d'aversion au risque : un investisseur très averse au risque se positionnera sur la partie gauche (faible variance, faible rendement), tandis qu'un investisseur plus agressif choisira un portefeuille plus à droite. Ce choix se formalise par la maximisation d'une fonction d'indifférence dans l'espace $(\sigma, E(R))$, dont la pente reflète l'aversion au risque individuelle.

El Bouhadi et al. (2008) ont appliqué cette méthodologie à 31 actions cotées à la Bourse des Valeurs de Casablanca. Leurs résultats sont instructifs : la frontière efficiente est constructible, mais elle est sensible à la période d'estimation des paramètres et aux problèmes de stationnarité des séries de rendements. Les tests ADF et de Phillips-Perron qu'ils appliquent confirment la stationnarité des rendements, après différenciation, ce qui valide l'usage des méthodes classiques d'optimisation. Cependant, les résultats sont fortement

dépendants de la fenêtre temporelle retenue, ce qui plaide pour une approche glissante plutôt que statique.




Figure 1.2 : Application de la frontière efficiente aux actions cotées à la Bourse de Casablanca

Source : El Bouhadi, Ounir & El Maguiri (2008)

Au-delà de sa valeur théorique, la frontière efficiente souffre en pratique de limitations importantes que Poncet et Portait (2009) ne minimisent pas. La construction du portefeuille efficient requiert l'estimation de n rendements espérés, n variances et $n(n-1)/2$ covariances. Pour un univers de 77 actifs comme le nôtre (l'ensemble des entreprises cotées à la BVC) : cela représente pas moins de 3 080 paramètres à estimer, chacun sujet à une erreur d'estimation. L'accumulation de ces erreurs peut conduire à des portefeuilles efficients théoriquement mais très sensibles aux données d'entrée. C'est l'un des problèmes que notre approche par apprentissage automatique cherche précisément à atténuer, en substituant des prévisions robustes aux estimations ponctuelles classiques.

Section 2 : Les indicateurs de mesure du risque financier

Si la variance constitue la mesure de risque canonique du modèle de Markowitz, elle est loin de suffire pour rendre compte de la complexité du risque financier réel. Deux portefeuilles peuvent afficher exactement la même volatilité annualisée tout en présentant des profils de risque radicalement différents. L'un peut subir des pertes extrêmes rares mais dévastatrices ; l'autre peut connaître des périodes prolongées de sous-performance qui épuisent financièrement et psychologiquement l'investisseur. Pour capturer ces dimensions multiples du risque, notre analyse mobilise vingt indicateurs organisés en six familles complémentaires.

2.1 Rendement et volatilité : les paramètres fondamentaux

Le rendement annualisé et la volatilité annualisée constituent les deux piliers de toute analyse de portefeuille. Ils ne se réduisent pas à de simples statistiques descriptives : ils incarnent le compromis rendement-risque au cœur de la théorie de Markowitz et servent de base au calcul de la quasi-totalité des autres indicateurs présentés dans cette section.

Le rendement annualisé Ra mesure le taux de croissance composé d'un investissement exprimé en rythme annuel, calculé à partir des rendements journaliers selon :

$$Ra = (1 + Rp)^{(252/T)} - 1$$

où T représente le nombre de jours de trading observés. La volatilité annualisée σa annualise l'écart-type des rendements journaliers en multipliant par la racine du nombre de jours de trading :

$$\sigma a = \sigma_{journalière} \times \sqrt{252}$$

Ces deux indicateurs forment ce qu'on pourrait appeler le « passeport » de chaque action : ils donnent une première lecture rapide du profil rendement-risque avant que les indicateurs plus sophistiqués n'en affinent le portrait. Mais la volatilité historique, telle que nous la calculons ici, est une mesure rétrospective et inconditionnelle. Elle suppose implicitement que la variance des rendements est constante dans le temps, hypothèse démentie par la réalité des marchés financiers.

En effet, Engle (1982) a introduit les modèles ARCH pour modéliser précisément cette variance conditionnelle et ses clusters de volatilité, soit des phases de calme alternant avec des périodes de forte turbulence. Rhatous et Daoui (2020) confirment ce phénomène sur le marché boursier marocain en montrant que les modèles GARCH capturent significativement mieux la dynamique de la volatilité de la BVC que les mesures historiques inconditionnelles. Cette observation renforce l'intérêt d'une approche dynamique à fenêtres glissantes, que nous adoptons dans notre partie empirique, plutôt que d'une estimation statique sur l'ensemble de la période.

L'extension EGARCH (Exponential GARCH), introduite par Nelson (1991) et citée par Rhatous et Daoui (2020), apporte une dimension supplémentaire cruciale : l'asymétrie de la réponse de la volatilité aux chocs. Dans un modèle GARCH symétrique, un choc positif et un choc négatif de même amplitude produisent exactement la même hausse de volatilité. Or l'observation empirique contredit systématiquement cette symétrie : une mauvaise nouvelle amplifie la volatilité bien davantage qu'une bonne nouvelle de même ampleur, phénomène dit d'« effet de levier ». Sur la BVC, où les chocs négatifs (retraits institutionnels, dégradations souveraines, tensions régionales) tendent à être particulièrement abruptes, cette asymétrie est structurellement importante et sera prise en compte dans notre modélisation de la variance conditionnelle.

Un troisième niveau de complexité mérite d'être signalé, encore peu mobilisé dans la littérature marocaine : la mémoire longue de la volatilité. Là où les modèles GARCH supposent que les chocs de volatilité s'amortissent exponentiellement, dite mémoire courte, Coulon (2009) démontre que la volatilité réalisée suit en réalité un processus à mémoire longue, dont les autocorrélations décroissent selon une loi de puissance bien plus lente. Ce phénomène a une implication directe pour les marchés émergents : Di Matteo, Aste et Dacorogna (2005) ont établi que les marchés moins matures et moins liquides exhibent une mémoire longue plus prononcée que les marchés développés. La BVC, marché en développement à liquidité structurellement limitée, serait donc particulièrement concernée par ce biais, ce qui plaide pour des fenêtres d'estimation suffisamment longues et des modèles capables de capturer cette persistance dans notre approche de prévision du risque.

2.2 Indicateurs de marché : bêta, alpha et tracking error

Les indicateurs de marché mesurent la relation entre un titre et son indice de référence. Dans notre contexte, l'indice MASI (Moroccan All Shares Index) constitue le benchmark naturel. Ces indicateurs sont précieux pour distinguer ce qui relève de l'exposition au marché de ce qui relève de la performance intrinsèque du titre.

Le bêta (β) quantifie la sensibilité d'un titre aux mouvements du MASI. Un bêta de 1,2 signifie que si le MASI progresse de 10 %, le titre tend à progresser de 12 %, et à baisser de 12 % lors d'une correction de 10 %. Les titres à bêta élevé (dit « agressifs ») amplifient les cycles de marché ; les titres à faible bêta (« défensifs ») les amortissent. Sa formule :

$$\beta = \text{Cov}(R_i, R_m) / \text{Var}(R_m)$$

Sur la BVC, une particularité mérite d'être soulignée : Moumni (2007) a démontré que la relation rendement-bêta est conditionnelle à l'état du marché. En phase haussière, les titres à fort bêta surperforment comme prévu ; en phase baissière, ils sous-performent d'autant plus. Mais sur un marché à faible liquidité, ce comportement peut être amplifié par des effets de microstructure (écarts de cours acheteur-vendeur importants, transactions en bloc) qui

perturbent les estimations du bêta sur de courtes fenêtres. C'est pourquoi notre analyse calcule le bêta sur des fenêtres glissantes, permettant de capturer son instabilité temporelle.

L'alpha (α) représente le rendement excédentaire généré au-delà de ce que l'exposition au marché laissait espérer. C'est la signature de la surperformance, voire de la sous-performance, propre au titre, indépendamment des conditions générales. Un alpha positif persistant est l'objectif premier de toute gestion active, et sa génération justifie les frais de gestion prélevés par rapport à une simple répllication indicielle.

$$\alpha = Ra - [Rf + \beta \cdot (Rm - Rf)]$$

Le tracking error (TE) mesure l'écart-type de la différence de rendements entre le portefeuille et le MASI. Sur la BVC, un tracking error structurellement élevé peut signaler non pas une gestion active volontaire, mais simplement un problème de liquidité sur certains titres, nuance que notre analyse empirique prendra en compte lors de l'interprétation des résultats.

$$TE = \sigma(R_i - Rm)$$

2.3 Ratios de performance ajustée au risque

Ces ratios répondent à une question simple mais fondamentale : est-ce que le rendement obtenu justifie le risque pris ? Cette question admet plusieurs réponses selon la définition du « risque » retenue ; c'est précisément pour cette raison que nous mobilisons cinq ratios complémentaires plutôt qu'un seul.

Le ratio de Sharpe, le plus utilisé en pratique, rapporte l'excès de rendement sur le taux sans risque à la volatilité totale (Sharpe, 1966) :

$$S = (Ra - Rf) / \sigma a$$

Son principal défaut est bien connu : en pénalisant symétriquement les écarts positifs et négatifs par rapport à la moyenne, il traite la volatilité haussière comme un risque, ce qu'elle n'est manifestement pas pour l'investisseur. Bailey et López de Prado (2012) vont plus loin en montrant que le ratio de Sharpe est statistiquement peu fiable sur des historiques courts, et qu'il peut induire en erreur lorsque les rendements présentent une asymétrie négative ou un excès de kurtosis. Cette limite est particulièrement pertinente sur la BVC, où les historiques liquides sont parfois limités à quelques années. De plus, deux stratégies peuvent afficher le même ratio de Sharpe tout en étant radicalement différentes : l'une avec une volatilité régulière et modérée, l'autre avec des rendements plats ponctuées de crises violentes. C'est là qu'interviennent les quatre autres ratios.

Pour remédier à cette fragilité statistique, Bailey et López de Prado (2012) proposent le Ratio de Sharpe Probabiliste (PSR, Probabilistic Sharpe Ratio), qui évalue la probabilité qu'un

ratio de Sharpe estimé reflète réellement une compétence et non simplement de la chance. Sa formulation intègre explicitement l'asymétrie (γ_3) et l'excès de kurtosis (γ_4) des rendements :

$$PSR(SR^*) = \Phi(\sqrt{T-1} \cdot (\hat{SR} - SR^*) / \sqrt{(1 - \gamma_3 \cdot \hat{SR} + ((\gamma_4 - 1)/4) \cdot \hat{SR}^2)})$$

où T est la longueur de l'historique, SR^* un seuil de référence et Φ la fonction de répartition normale standard. De ce résultat découle la notion de longueur minimale de track record (MinTRL) : la durée d'observation nécessaire pour rejeter l'hypothèse nulle de compétence nulle avec un niveau de confiance donné. Sur la BVC, où certains titres ne disposent que de trois à cinq ans d'historique liquide, le PSR constitue un garde-fou essentiel contre la surinterprétation de ratios de Sharpe apparemment attractifs mais statistiquement non significatifs. Dans notre analyse empirique, nous reporterons systématiquement le PSR aux côtés du Sharpe traditionnel pour chaque stratégie évaluée.

Le ratio de Sortino corrige l'asymétrie du Sharpe en ne pénalisant que les rendements inférieurs à un seuil cible T (Sortino & Van der Meer, 1991) :

$$Sortino = (Ra - T) / DD \quad \text{où} \quad DD = \sqrt{[(1/n) \cdot \sum \min(R_i - T, 0)^2]}$$

En remplaçant la volatilité totale par la semi-déviations à la baisse, le Sortino récompense les portefeuilles dont la volatilité est principalement haussière. C'est un indicateur plus fin que le Sharpe pour évaluer une stratégie à rendements asymétriques, profil fréquent sur les marchés émergents.

Le ratio de Calmar rapporte le rendement annualisé à la pire perte jamais subie (max drawdown). Il donne une lecture du rendement sous l'angle des scénarios catastrophiques historiques, ce qui en fait l'indicateur de référence pour les investisseurs particulièrement sensibles aux risques de perte extrême :

$$Calmar = Ra / |Max Drawdown|$$

Le ratio d'information mesure quant à lui l'efficacité de la gestion active : combien d'alpha génère-t-on par unité de tracking error supportée ? Un information ratio élevé signifie que la déviation par rapport au benchmark est rentable ; un ratio faible ou négatif signale une gestion active qui détruit de la valeur relativement à une simple réplique indicielle du MASI :

$$IR = (Ra - Rm) / TE$$

Enfin, le ratio Omega constitue la mesure de performance la plus exhaustive. Proposé par Keating et Shadwick (2002), il ne requiert aucune hypothèse distributionnelle et intègre l'ensemble de l'information contenue dans la distribution empirique des rendements. Il est défini comme le rapport entre le potentiel haussier et le potentiel baissier relativement à un seuil τ :

$$\Omega(\tau) = \int_{[\tau, +\infty]} [1 - F(r)] dr / \int_{[-\infty, \tau]} F(r) dr$$

Un Omega supérieur à 1 signifie que le potentiel haussier l'emporte sur le potentiel baissier : le portefeuille est « rentable » au sens Omega. Kapsos et al. (2011) ont démontré que la maximisation de ce ratio peut être formulée comme un programme linéaire, rendant son utilisation pratique même pour des univers d'investissement de grande taille comme le nôtre.

Figure 1.3 : Comparaison des cinq ratios de performance : complémentarité des lectures du risque

Source : Adapté de Bailey & López de Prado (2012) et Kapsos et al. (2011)

2.4 Mesures de risque de queue : VaR, CVaR et Max Drawdown

Les crises financières de 2000 et 2008 ont rappelé brutalement que les marchés ne se comportent pas comme des distributions normales. Les queues de distribution (les événements extrêmes, rares mais dévastateurs) sont systématiquement sous-estimées par la seule variance. Ce sont précisément ces événements que les mesures de risque de queue cherchent à capturer (Jorion, 2007).

La Value at Risk (VaR) à 95 % répond à une question précise : quelle est la perte maximale que l'on peut subir dans 95 % des cas sur un horizon donné ? Il n'y a donc que 5 % de probabilité que la perte réelle dépasse ce seuil. Sa popularité tient à son intuitivité et à son adoption par la réglementation bancaire internationale (Bâle II et III). Elle se calcule sur notre échantillon directement à partir du 5e percentile de la distribution empirique des rendements.

Mais la VaR souffre d'une limitation fondamentale : elle ne dit rien sur ce qui se passe dans les 5 % restants. Deux portefeuilles peuvent afficher la même VaR à 95 % tout en présentant des pertes très différentes dans les scénarios extrêmes, l'un avec des pertes légèrement supérieures au seuil, l'autre avec des effondrements catastrophiques. C'est la lacune que corrige la CVaR (Conditional Value at Risk), aussi appelée Expected Shortfall :

$$CVaR_{0.95} = E[L \mid L > VaR_{0.95}]$$

La CVaR mesure la perte moyenne conditionnellement aux scénarios qui dépassent la VaR. Rockafellar et Uryasev (2000) ont démontré qu'elle possède des propriétés mathématiques supérieures à la VaR, notamment la sous-additivité, qui garantit que la CVaR d'un portefeuille diversifié est inférieure ou égale à la somme des CVaR individuelles. Elle est donc une mesure de risque cohérente au sens d'Artzner et al. (1999), ce que la VaR n'est pas. Sur la BVC, où les épisodes de faible liquidité peuvent générer des pertes extrêmes brutales, la CVaR s'impose comme une mesure de risque bien plus informative que la VaR seule.

Le maximum drawdown (MDD) apporte une troisième lecture, complémentaire aux deux précédentes. Là où la VaR et la CVaR raisonnent sur des distributions de rendements, le MDD mesure la pire trajectoire historique réelle : quelle est la perte cumulée maximale depuis un sommet jusqu'au creux suivant ? Pour un investisseur ayant acheté au plus haut, c'est la

perte effective qu'il aurait subie avant de retrouver son niveau d'investissement initial. Bousquet-Racine (2020) propose des approches d'optimisation sous contrainte explicite de drawdown maximal, une direction que nous explorerons dans notre section d'optimisation dynamique.

$$MDD = \max_{t \in [0, T]} [\max_{s \in [0, t]} V(s) - V(t)] / \max_{s \in [0, t]} V(s)$$




Figure 1.4 : Illustration du maximum drawdown : trajectoire de valeur d'un portefeuille et perte cumulée

Source : Adapté de Bousquet-Racine (2020)

2.5 Asymétrie et aplatissement : les moments oubliés de la distribution

Un actif peut afficher un ratio de Sharpe attractif tout en dissimulant un risque considérable si ses rendements sont fortement asymétriques ou à queues épaisses. L'asymétrie (skewness) et l'aplatissement (kurtosis) constituent les moments d'ordre 3 et 4 de la distribution, trop souvent ignorés dans les analyses classiques centrées sur la moyenne et la variance.

El Bouhadi et al. (2008) ont appliqué des tests de normalité à 31 titres de la BVC et obtenu un résultat révélateur : le coefficient de skewness est négatif pour 15 des 31 valeurs, signifiant que la partie épaisse de leur distribution est du côté des pertes. Les statistiques de Jarque-Bera rejettent la normalité pour la quasi-totalité des titres. Ces résultats empiriques directement issus du marché marocain confirment que les modèles basés sur la seule variance sous-estiment systématiquement le risque réel des titres cotés à la BVC.

Une asymétrie négative (distribution penchée à gauche) signale que les gains habituels sont réguliers et modérés, mais que les pertes extrêmes sont fréquentes et importantes. C'est le

profil classique d'une stratégie qui « ramasse des centimes devant un rouleau compresseur » : des performances régulières, ponctuées de crises violentes. L'excès de kurtosis confirme et quantifie le caractère leptokurtique des distributions, avec des queues plus épaisses qu'une loi normale, impliquant une probabilité bien plus élevée d'événements extrêmes que ce que la variance laisserait supposer.

$$Skewness = E[(R - \mu)^3] / \sigma^3$$

$$Kurtosis = E[(R - \mu)^4] / \sigma^4$$

Bailey et López de Prado (2012) insistent sur le fait que ces deux paramètres doivent impérativement être pris en compte pour interpréter correctement le ratio de Sharpe. En particulier, une stratégie à asymétrie négative et kurtosis élevé verra son Sharpe probabiliste (c'est-à-dire la probabilité statistique que le Sharpe observé reflète une compétence réelle et non de la chance) se dégrader sensiblement par rapport à son Sharpe traditionnel. Ignorer ces moments supérieurs, c'est s'exposer à une évaluation systématiquement biaisée des performances sur la BVC.

2.6 Pain Index et Ulcer Index : quantifier la durée de la souffrance

Les deux derniers indicateurs de notre tableau de bord abordent une dimension souvent négligée dans la littérature académique, mais bien réelle dans la pratique quotidienne de la gestion : combien de temps un investisseur supporte-t-il des pertes ? La durée et la persistance des drawdowns ont un impact psychologique et financier considérable : elles peuvent pousser des investisseurs à sortir au pire moment, cristallisant des pertes qui auraient pu être récupérées avec plus de patience.

L'Ulcer Index, proposé par Martin et McCann (1989), quantifie cette dimension en calculant la racine carrée de la moyenne des carrés des drawdowns journaliers. En mettant les drawdowns au carré avant de les moyenner, il accorde davantage de poids aux pertes profondes et prolongées, pénalisant fortement les stratégies à longues périodes de sous-performance :

$$UI = \sqrt{[(1/T) \cdot \sum_i D_i^2]}$$

Le Pain Index adopte une approche plus linéaire : il calcule simplement la moyenne arithmétique des drawdowns journaliers, sans les mettre au carré. Il est ainsi moins sensible aux pics de perte extrêmes et rend mieux compte de l'inconfort moyen subi sur l'ensemble de la période d'observation :

$$PI = (1/T) \cdot \sum_i |D_i|$$

Ces deux indicateurs prennent une pertinence toute particulière dans le contexte boursier marocain. Les phases de faible liquidité, notamment lors des chocs régionaux ou des crises des matières premières (pétrole, phosphates), peuvent maintenir des investisseurs en drawdown pendant des mois, voire des années. Un portefeuille affichant un bon ratio de

Sharpe peut ainsi avoir un Ulcer Index très élevé, ce qui signifie que la performance agrégée est satisfaisante, mais que le chemin pour y parvenir a été particulièrement douloureux. Notre agent IA intégrera explicitement ces dimensions dans son processus de sélection et d'évaluation des portefeuilles générés.

Figure 1.5 : Vue synthétique des vingt indicateurs de risque par catégorie analytique

Source : Élaboration propre, à partir de la revue de la littérature

Chapitre 2

Intelligence artificielle et automatisation en gestion d'actifs

Le premier chapitre a posé un constat clair : les outils mathématiques classiques de la gestion de portefeuille fonctionnent bien dans un monde ordonné et prévisible, mais les marchés financiers réels sont tout sauf ça. Les prix montent et descendent de façon irrégulière, les crises arrivent sans prévenir, et les relations entre les actifs changent au fil du temps. Face à ces limites, un nouveau champ technologique a émergé ces dernières décennies : l'intelligence artificielle. Plutôt que de forcer les données à rentrer dans un modèle théorique préétabli, l'IA apprend directement à partir des données ; elle détecte les motifs, les tendances et les anomalies que l'œil humain ou les formules classiques ne parviennent pas à saisir.

Ce chapitre présente l'intelligence artificielle telle qu'elle s'applique à la gestion d'actifs. Il est important de préciser d'emblée que nous nous trouvons encore aux premières heures de cette révolution technologique dans le domaine financier : les recherches se multiplient, les résultats sont prometteurs, mais les applications à grande échelle restent récentes et les défis nombreux. La première section définit ce qu'est concrètement un agent IA et comment il est structuré. La seconde section passe en revue les principales applications déjà testées et déployées en gestion de portefeuille à travers le monde.

Section 1 : Les agents IA : définition et architecture

1.1 De l'intelligence artificielle aux agents : filiation conceptuelle

Pour bien comprendre ce qu'est un agent IA, il faut d'abord savoir que l'intelligence artificielle n'est pas un concept unique mais une famille de technologies emboîtées les unes dans les autres. Sutiene et al. (2024), dans une revue académique publiée dans *Frontiers in Artificial Intelligence*, proposent une image claire de cette organisation : au niveau le plus large, l'intelligence artificielle désigne tout système informatique conçu pour reproduire des capacités cognitives humaines, telles que raisonner, apprendre, décider, reconnaître. À l'intérieur de ce grand domaine se trouve le machine learning, ou apprentissage automatique : c'est l'ensemble des méthodes qui permettent à un programme d'apprendre par lui-même à partir de données, sans qu'un programmeur ait besoin de lui écrire toutes les règles à suivre. C'est la différence entre un programme qu'on programme explicitement pour reconnaître un chat, et un programme qui regarde des milliers de photos de chats et apprend tout seul à les reconnaître. À l'intérieur du machine learning se trouvent les réseaux de neurones artificiels, inspirés du cerveau humain. À l'intérieur des réseaux de neurones, le deep learning désigne les architectures les plus profondes, capables d'apprendre des représentations très complexes à partir de grandes quantités de données.

Un agent IA est un cas particulier de système intelligent. Russell et Norvig (2010), dont le manuel est la référence mondiale en intelligence artificielle, définissent un agent très simplement : c'est « *tout système qui observe son environnement et prend des actions en réponse* ». Ce qui le distingue d'un simple programme, c'est son autonomie et sa capacité d'adaptation. Un programme classique exécute toujours les mêmes instructions peu importe ce qui se passe. Un agent, lui, observe ce qui l'entoure, réfléchit, et choisit la meilleure action possible pour atteindre son objectif, même si la situation est nouvelle ou inattendue. Appliqué à la finance, un agent IA observe les marchés (prix, volumes, indicateurs de risque), analyse ces informations avec ses modèles d'apprentissage, et formule une décision : acheter, vendre, rééquilibrer, ou alerter le gestionnaire.

La distinction entre un simple modèle de prédiction et un véritable agent mérite d'être soulignée, car elle est fondamentale. Un modèle prédit : il reçoit des données en entrée et produit un chiffre en sortie, par exemple la volatilité prévue demain. Un agent décide : il intègre cette prédiction dans un raisonnement plus large, tient compte de l'état actuel du portefeuille, des contraintes de risque fixées, et propose une action concrète. L'agent fonctionne en boucle continue (observer, analyser, agir, observer à nouveau) et s'adapte au fil du temps à l'évolution du marché. C'est cette capacité d'adaptation continue qui le rend particulièrement pertinent pour des marchés dont les dynamiques changent, comme le montrent López de Prado (2018) et Gu, Kelly et Xiu (2020).

1.2 Les différents types d'agents IA

Tous les agents IA ne se ressemblent pas. Selon la façon dont ils traitent l'information et prennent leurs décisions, la littérature distingue trois grandes catégories, chacune avec ses forces et ses limites.

Le premier type est l'agent réactif. Il fonctionne comme un réflexe : il observe la situation du moment et réagit immédiatement selon des règles fixes, sans chercher à comprendre le contexte global ni à anticiper l'avenir. Par exemple, un système qui vend automatiquement une action dès que son prix baisse de 5 % est un agent réactif. Ces systèmes sont très rapides, mais limités : ils ne s'adaptent pas, ne comprennent pas le « pourquoi » des événements, et peuvent réagir de façon inappropriée dans des situations nouvelles. Da Silva (2024) note que les premières générations de systèmes algorithmiques en finance appartiennent à cette catégorie, et qu'elles se révèlent insuffisantes face à la complexité des marchés modernes.

Le deuxième type est l'agent délibératif. Contrairement à l'agent réactif, il ne se contente pas de réagir : il maintient une représentation de son environnement, planifie ses actions sur

plusieurs étapes et cherche à atteindre un objectif à moyen terme. C'est un peu comme un joueur d'échecs qui ne joue pas le premier coup qui lui vient en tête, mais qui réfléchit à plusieurs coups à l'avance. En gestion de portefeuille, un agent délibératif peut simuler différentes configurations d'allocation, évaluer leurs conséquences en termes de risque et de rendement, et choisir la meilleure option sur un horizon de plusieurs semaines ou mois.

Le troisième type, et le plus utilisé en pratique, est l'agent hybride. Il combine les deux approches précédentes : une couche réactive pour traiter rapidement les signaux urgents du marché, et une couche délibérative pour la planification stratégique. Zhang (2014), dans ses travaux à Télécom ParisTech, montre que cette architecture hybride est la mieux adaptée aux systèmes de gestion d'actifs déployés en conditions réelles : la partie réactive gère les alertes immédiates, tandis que la partie délibérative supervise la cohérence globale du portefeuille dans le temps.

Une quatrième catégorie, très récente, commence à émerger dans la littérature : les agents fondés sur les grands modèles de langage (LLMs, pour Large Language Models), dont ChatGPT est l'exemple le plus connu du grand public. Ces agents ont la particularité de comprendre et de produire du langage naturel, ce qui leur permet d'analyser des informations textuelles (actualités financières, rapports d'entreprises, annonces de banques centrales) et de les intégrer dans leurs décisions aux côtés des données chiffrées classiques. Da Silva (2024) souligne que cette capacité ouvre des perspectives inédites, car une grande partie de l'information financière pertinente n'est pas numérique mais narrative, et était jusqu'ici inaccessible aux modèles quantitatifs traditionnels.

1.3 Comment fonctionne un agent IA : la boucle perception-raisonnement-action

Au cœur de tout agent IA se trouve une boucle simple qui se répète indéfiniment : observer, raisonner, agir. Anthropic (2024), dans un document de référence sur la conception d'agents, décrit cette boucle comme la pierre angulaire de tout système agentique : l'agent perçoit son environnement (les données qui lui parviennent), utilise un modèle de raisonnement pour décider quoi faire, exécute une action (par exemple consulter une base de données, recalculer un indicateur de risque ou proposer une allocation), puis observe les résultats de cette action et recommence. C'est cette boucle continue qui distingue fondamentalement un agent d'un simple programme de calcul : le programme s'arrête après avoir produit une réponse ; l'agent continue à observer et à s'adapter.

Pour interagir avec son environnement, un agent s'appuie sur des outils, c'est-à-dire des fonctions qu'il peut appeler pour obtenir des informations ou déclencher des actions. Anthropic (2024) utilise l'expression « interface agent-ordinateur » pour décrire cet ensemble d'outils : ils sont pour l'agent ce que les mains et les yeux sont pour un humain. En finance, ces outils peuvent être une connexion à une base de données de cours boursiers, un moteur de calcul de métriques de risque, un optimiseur de portefeuille, ou encore un module d'affichage

des résultats à destination du gestionnaire. Sutiene et al. (2024) confirment ce schéma en décomposant le processus de l'agent en trois étapes successives : planification des objectifs, exécution des décisions, et retour d'expérience pour se recalibrer.

Une distinction importante, souvent mal comprise, sépare les agents des simples automatisations. Anthropic (2024) distingue deux grandes catégories de systèmes : les flux de travail automatisés, où les étapes sont définies à l'avance par le programmeur, et les agents au sens strict, où c'est le système lui-même qui décide de la séquence d'étapes à suivre en fonction de la situation. Un système qui calcule toujours les mêmes indicateurs dans le même ordre est un flux de travail automatisé. Un agent, lui, peut décider de recalculer un indicateur supplémentaire s'il détecte une anomalie, ou d'adopter une stratégie différente si les conditions de marché ont changé. Cette autonomie de raisonnement est la caractéristique centrale des agents IA.

Section 2 : Applications des agents IA en gestion d'actifs

2.1 Pourquoi les approches classiques ont-elles montré leurs limites ?

Pour comprendre pourquoi l'IA s'est imposée en gestion de portefeuille, il faut d'abord comprendre ce qui n'a pas fonctionné avant. Pendant des décennies, les professionnels de la finance ont misé sur la gestion active : des équipes d'analystes et de gérants cherchent à battre le marché en sélectionnant les meilleures actions. Mais les chiffres sont sévères : Sharpe (1991), Prix Nobel d'économie, a démontré mathématiquement que les gestionnaires actifs ne peuvent pas tous battre le marché en même temps, car leur ensemble constitue le marché lui-même. Les données récentes confirment : 84 % des fonds actifs américains et 73 % des fonds actifs européens ont sous-performé leur indice de référence sur les cinq dernières années (Wagner, 2018).

Face à cet échec de la gestion active classique, une alternative intermédiaire a émergé dans les années 2000 : le Smart Beta. L'idée est simple : au lieu de laisser un gérant humain choisir les actions, on construit un portefeuille en suivant des règles automatiques fondées sur des facteurs connus pour générer de la performance sur le long terme : les actions bon marché (facteur valeur), les actions qui ont bien monté récemment (facteur momentum), les petites entreprises (facteur taille), ou les actions peu volatiles (facteur faible volatilité). Mais là encore, les résultats déçoivent. Wagner (2018) a analysé 25 fonds Smart Beta sur cinq ans et conclu qu'aucun ne génère de performance ajustée au risque significativement supérieure à son indice de référence. Les règles simples ne suffisent pas non plus.

C'est dans ce contexte que la vision des marchés a évolué. Lo (2004), cité par Bohren (2022), propose l'hypothèse des marchés adaptatifs : les marchés ne sont pas toujours efficaces ni toujours exploitables ; ils oscillent entre des périodes où les opportunités existent et des périodes où elles disparaissent, selon la concurrence entre investisseurs. Cette vision dynamique appelle des outils eux aussi dynamiques, capables de s'adapter aux changements de régime de marché. C'est précisément le rôle que l'intelligence artificielle peut jouer. Qui plus est, Giglio et al. (2008), cités par Bohren (2022), ont établi que les marchés émergents présentent des inefficiences plus durables que les marchés développés, ce qui rend le potentiel de l'IA encore plus intéressant sur ces marchés.

L'industrie financière mondiale a commencé à prendre la mesure de ce potentiel. Alfzari et al. (2025), dans une enquête menée auprès de 200 gestionnaires de portefeuille, constatent que 90 % des firmes interrogées utilisent désormais l'IA sous une forme ou une autre : 30,5 % pour le trading algorithmique, 26,5 % pour les robo-advisors, et 24 % pour l'analyse prédictive. Da Silva (2024) rapporte que cette transition est très récente : en 2020, seulement 6 % des gestionnaires utilisaient effectivement l'IA dans leurs décisions, mais 76 % déclaraient vouloir le faire dans les années suivantes. Nous sommes donc au tout début d'une transformation profonde du métier de la gestion d'actifs.

2.2 Le deep learning comme moteur de prévision de l'agent

Le deep learning est la branche du machine learning qui a produit les avancées les plus spectaculaires de ces dernières années ; c'est la technologie derrière la reconnaissance faciale, les voitures autonomes et ChatGPT. En finance, son application la plus directe est la prévision de séries temporelles : prédire comment vont évoluer les prix, la volatilité ou le risque dans les jours et semaines à venir.

La méthode qui a le plus retenu l'attention des chercheurs en finance est le LSTM (Long Short-Term Memory, que l'on peut traduire par « mémoire longue et courte »). Pour comprendre son intérêt, il faut savoir que les séries financières ont une propriété particulière : ce qui s'est passé il y a un mois, six mois, ou même un an peut encore influencer ce qui se passe aujourd'hui. Les méthodes statistiques classiques comme ARIMA ont du mal à capturer ces dépendances de long terme. Le LSTM a été précisément conçu pour résoudre ce problème : il possède une « mémoire » qui lui permet de décider quelles informations passées garder en tête et lesquelles oublier, en fonction de leur pertinence pour la prédiction actuelle. Sutiene et al. (2024) confirment que le LSTM surpasse ARIMA par une marge significative sur les données financières.

Alonso et Ordieres-Meré (2025), dans une étude publiée dans le Journal of Forecasting, une revue académique internationale de référence, une approche encore plus avancée : combiner plusieurs algorithmes de deep learning avec une optimisation de portefeuille. Leur système utilise d'abord le LSTM pour prévoir les performances futures de chaque action, puis utilise ces prévisions pour calculer la meilleure répartition possible entre les actifs, en imposant qu'au minimum N secteurs différents soient représentés dans le portefeuille pour garantir la diversification. Leurs résultats montrent que le LSTM est le plus précis sur le court terme (environ 30 jours), tandis que les Transformers, l'architecture qui a révolutionné le traitement du langage naturel et dont GPT est un exemple, sont plus stables sur des horizons plus longs.

2.3 Des exemples concrets d'agents IA déployés en finance

Au-delà des résultats académiques, il est instructif de voir comment des agents IA ont été concrètement déployés dans l'industrie financière réelle. Ces exemples montrent que ce n'est pas uniquement de la théorie.

Le premier exemple marquant est le système PRISMS, documenté par Zhang (2014). Développé dans le cadre d'une thèse à Télécom ParisTech, ce système a été déployé en production à la division Recherche Quantitative d'Exane BNP Paribas à partir de janvier 2012. Concrètement, chaque mois, PRISMS analyse un univers d'actions européennes et produit des recommandations automatiques sur lesquelles miser à la hausse et lesquelles éviter. Pour ce faire, il utilise des forêts aléatoires entraînées sur des dizaines d'indicateurs de marché, et

traite plusieurs centaines d'actions simultanément en exploitant les corrélations entre elles. C'est l'un des premiers exemples documentés d'un agent IA basé sur le machine learning opérant en conditions réelles dans une banque d'investissement européenne.

Le deuxième exemple, plus grand public, est celui des robo-advisors, littéralement des « conseillers robots ». Ces plateformes permettent à n'importe quel particulier de confier ses économies à un système automatisé qui gère son portefeuille sans intervention humaine permanente. Le client définit son profil (combien de risque il accepte, sur quel horizon il investit) et le robot s'occupe du reste : il répartit l'argent entre différentes classes d'actifs, surveille en permanence et rééquilibre automatiquement quand nécessaire. Wealthfront, l'un des pionniers américains du secteur, gère déjà 2 milliards de dollars de cette façon en 2016 (Zhang & Chen, 2017). Da Silva (2024) précise que le marché mondial des robo-advisors a atteint 7,39 milliards de dollars en 2023, témoignant d'une croissance très rapide de la confiance des investisseurs envers ces systèmes automatisés.

Le troisième exemple est le trading algorithmique. Aujourd'hui, entre 40 % et 70 % des ordres passés sur les grandes bourses mondiales sont exécutés par des algorithmes, non par des humains (Da Silva, 2024). Ces systèmes détectent des opportunités d'achat ou de vente en quelques millisecondes, vitesse impossible pour un être humain, et agissent avant que l'opportunité ne disparaisse. Ils sont l'expression la plus visible de la transformation algorithmique des marchés financiers. Alfzari et al. (2025) confirment que 30,5 % des gestionnaires interrogés utilisent le trading algorithmique comme principale forme d'intégration de l'IA dans leur activité.

2.4 Les défis réels de l'IA en gestion de portefeuille

L'enthousiasme autour de l'IA ne doit pas masquer les difficultés concrètes que son application en finance soulève. Ces défis sont réels et reconnus par l'ensemble des chercheurs et praticiens du domaine.

Le premier défi est ce que les spécialistes appellent le surapprentissage. Un modèle de deep learning contient parfois des millions de paramètres ajustables. Si on lui donne trop de liberté pendant l'entraînement, il finit par mémoriser les données historiques au lieu d'en apprendre les principes généraux, exactement comme un étudiant qui apprend les réponses par cœur sans comprendre le cours, et qui échoue face à une question légèrement différente. En finance, un modèle surappris donne l'illusion d'excellentes performances sur les données passées, mais se révèle inutile, voire dangereux, sur des données futures. López de Prado (2018) insiste sur l'importance de protocoles de test rigoureux pour détecter ce problème avant tout déploiement.

Le deuxième défi est celui de la boîte noire. Un réseau de neurones profond peut impliquer des millions d'opérations mathématiques entre l'entrée (les données de marché) et la

sortie (la recommandation). Personne, pas même ses concepteurs, ne peut expliquer précisément pourquoi il a recommandé d'acheter telle action plutôt que telle autre. Alfzari et al. (2025) rapportent que c'est la principale réticence des gestionnaires interrogés : comment expliquer à un client, à un régulateur, ou à un comité de risque qu'un algorithme a pris une décision sans pouvoir en donner les raisons ? En réponse à ce défi, un nouveau domaine a émergé : l'IA explicable (XAI), dont l'objectif est de rendre les décisions des algorithmes partiellement compréhensibles par des humains (Sutiene et al., 2024).

Le troisième défi est la qualité des données. L'IA n'est aussi bonne que les données sur lesquelles elle s'entraîne, principe résumé dans l'expression anglaise « garbage in, garbage out ». En finance, les données historiques contiennent souvent des erreurs, des valeurs manquantes, des jours sans transaction sur certains titres, ou des ruptures dues à des changements de cotation. Alfzari et al. (2025) identifient la qualité des données comme le premier obstacle pratique à l'adoption de l'IA en gestion d'actifs. Ce défi est d'autant plus présent sur les marchés émergents, où les historiques sont souvent plus courts et moins homogènes que sur les grandes bourses mondiales.

Enfin, la question de la place de l'humain dans ce système mérite réflexion. L'IA ne remplace pas le gestionnaire : elle l'assiste. Alfzari et al. (2025) citent un responsable de robo-advisor : « Une implémentation réussie de l'IA requiert une approche collaborative qui combine les forces des humains et des machines. » Cette complémentarité est fondamentale. L'agent IA excelle dans le traitement rapide de grandes quantités de données et la détection de patterns statistiques. Le gestionnaire humain apporte ce que la machine ne peut pas avoir : le contexte géopolitique, la compréhension des dynamiques sectorielles locales, et la capacité à faire confiance ou non à une décision dans une situation véritablement inédite.

Conclusion de la Partie I

Cette première partie a posé les deux piliers sur lesquels repose l'ensemble de ce travail. Le premier pilier est théorique : la gestion de portefeuille a une histoire et des outils bien établis, à savoir la frontière efficiente de Markowitz, les mesures de risque variées (VaR, CVaR, Sharpe, Sortino, drawdown...), mais ces outils ont été conçus pour un monde idéal que les marchés réels ne respectent pas toujours. La BVC, avec sa concentration sectorielle, sa liquidité variable et ses distributions non normales, en est un exemple concret.

Le deuxième pilier est technologique : l'intelligence artificielle offre une nouvelle façon d'aborder ces problèmes. Plutôt que d'imposer des hypothèses simplificatrices aux données, elle apprend à partir de ces données telles qu'elles sont, avec toutes leurs irrégularités et leur complexité. Les premières applications en finance sont prometteuses, les exemples de déploiements réels existent, et l'adoption par l'industrie s'accélère. Mais nous sommes encore au début de cette transformation, et les défis pratiques restent nombreux.

C'est précisément à l'intersection de ces deux piliers que se situe la problématique de ce mémoire : peut-on construire un agent IA capable d'optimiser dynamiquement un portefeuille d'actions cotées à la Bourse de Casablanca, en s'appuyant sur des prévisions de risque fiables ? La Partie II répond à cette question par l'action et les données.